

Modelo híbrido para recomendación de películas. Una alternativa no tradicional

Jaramillo R., Jaime Andres.
jajaramil6@eafit.edu.co

Castañó M, Juan Pablo.
jpcastano@eafit.edu.co

Vera Ramírez, Santiago.
sverar1@eafit.edu.co

RESUMEN

Este trabajo busca tomar como base el modelo desarrollado por [1] para definir un problema de optimización multiobjetivo aplicado a recomendación de películas en el que se maximicen 3 métricas de distancia diferentes: exactitud (qué tan afines son los títulos al gusto de la persona), novedad (qué tan probable es que la persona nunca haya escuchado de la película) y diversidad (qué tan distintas son las opciones propuestas entre sí). Definidas todas las métricas a maximizar, el sistema de recomendación híbrido fue entrenado usando el algoritmo genético Non-Dominated Genetic Sorting Algorithm versión 2 (NGSA-II). Este toma como entrada una base de datos de calificaciones con cerca de 9000 películas diferentes. Como salida, el modelo nos entrega una lista de películas que al compararse empíricamente con recomendaciones hechas por otras plataformas como Netflix, deja claro el fuerte impacto que tiene considerar la diversidad y novedad en un sistema de recomendación.

INTRODUCCIÓN

Los sistemas de recomendación en la actualidad adquieren cada vez más y más relevancia con el ascenso de la ciencia de datos y el control que las empresas tienen sobre nuestras vidas. Este hecho es particularmente llamativo en el campo de las plataformas de contenido y el mercadeo, llegando en ocasiones a grandes niveles de precisión con respecto a lo que se muestra. Piense en cómo en ocasiones nos encontramos hablando acerca de un nuevo producto que estamos considerando comprar, solo para encontrarnos en nuestro feed anuncios acerca de productos relacionados horas después. Este hecho es posible gracias a los sistemas de recomendación. Hay dos tipos principales de estos, basados en el historial de un usuario y basados en criterios externos (como festividades, intereses de las empresas u opiniones de expertos) los cuales suelen buscar el mejor valor de una métrica. Considerando esto, podemos buscar optimizar múltiples métricas enmarcando la situación como un problema de optimización multiobjetivo el cual nos lleva a un tipo de recomendaciones diferentes [1].

El presente trabajo pretende mostrar e implementar un sistema de recomendación híbrido a la recomendación de películas. Aterrizando el problema a este contexto, es importante que las personas sean recomendadas películas con las cuales resuenen de esta manera por lo que es importante

servirse en un grado suficiente del perfil de películas con las que quisiera entrar en contacto la persona. Entre este valor sea mejor más probable es que le gusten a la persona. Esta métrica suele ser la más segura, de cualquier modo, es claro que ver constantemente contenido muy similar tiene la posibilidad de cansar al usuario por lo que considerar otras métricas tiene la posibilidad de dar mejores resultados. La novedad y la diversidad es una de las opciones tomadas por [1]. La novedad, nos habla, en términos generales, de películas que sean poco probables que el usuario haya visto antes; la cual es calculada en función a cuantas personas han visto una película. Al mostrar contenido que no muchas personas han visto, se logra ofrecer exposición a películas potencialmente buenas, que mantengan fresco el interés del usuario. Por parte de la diversidad, una lista en la que se muestren elementos lo suficientemente diferentes entre si, tiene una mayor probabilidad de que el tipo de recomendaciones a ofrecer cubra la mayor cantidad de cualidades de película dentro de cierto tipo.

Considerando esto terminamos con un problema de optimización multiobjetivo de las tres métricas planteadas. Para hacerle frente a este se optó, inspirándose en lo desarrollado en [1], por implementar un algoritmo genético para encontrar un frente de Pareto compuesto de listas de recomendaciones basándose del conjunto de datos de ratings de películas encontrado en [2].

METODOLOGÍA

Recolección de datos.

Los datos de las películas fueron obtenidos de la página de Group Lens, un laboratorio de investigación del Department of Computer Science and Engineering de la Universidad de Minnesota el cual estudia, entre otras cosas, sistemas de recomendación. Para efectos de este proyecto nos servimos de la base de datos que cuenta con 100836 ratings y 3683 etiquetas aplicadas a 9742 películas por 610 usuarios [2].

Formulación del problema matemático

Conjuntos

U : conjunto de todas las películas disponibles.

$u \in \mathcal{U}$: usuario para el que generamos recomendaciones.

Parámetros

k : número exacto de recomendaciones por usuario.
 m : número mínimo de géneros distintos en cada lista.
 $r_{u,p}$: rating (0–5) que el usuario u a la película p
 $I(u) = \{p \in U : r_{u,p}\}$ con $r_{u,p}$ definido: películas ya vistas (o valoradas) por u .
 $P(\text{Visto} \mid p)$: probabilidad de que un usuario cualquiera haya visto p .
 $\text{Pop}(p)$: popularidad de p (número de ratings totales de una película).
 T_{Pop} : máxima popularidad total permitida.
 T_{Nov} : mínima novedad por película.
 η_{min} : mínimo umbral para tomar $r_{u,p}$ como relevante.
 $\alpha \in [0, 1]$: peso para combinar distancias euclidiana y coseno.
 $g_{p,g} \in [0, 1]$: indica que la película p tiene el género g .
 $d_{eucl}(p, q)$: distancia euclidiana entre las películas.
 $d_{cos}(p, q)$: distancia del coseno entre las películas.

Variables de decisión.

Definimos una variable binaria para indicar la recomendación de la película a usuarios de la siguiente forma

$$x_{u,p} = \begin{cases} 1 & \text{si } p \text{ es recomendada al usuario } u, \\ 0 & \text{e.o.c} \end{cases}$$

Objetivos

1. Precisión:

$$\max Fe(u) = \frac{1}{k} \sum_{p \in U} r_{u,p} \cdot x_{u,p}$$

Definimos la precisión de groso modo para que, al momento de realizar la recomendación esta se acerque lo más posible a los gustos del usuario.

2. Novedad:

$$\max Fn(u) = \sum_{p \in U} (1 - P(\text{Visto} \mid p)) \cdot x_{u,p}$$

3. Diversidad: calculamos la diversidad como la suma ponderada de las distancias

$$\max Fd(u) = \alpha Fd_{eucl}(u) + (1 - \alpha) Fd_{cos}(u)$$

Sean dos películas $p, q \in U$ con $p \neq q$ donde la distancia euclidiana se define como

$$Fd_{eucl}(u) = \frac{1}{k(k-1)} \sum_{p,q \in U} x_{u,p} \cdot x_{u,q} \cdot d_{eucl}(p, q),$$

$$d_{eucl}(p, q) = \sqrt{\sum_{i=1}^n (v_{p,i} - v_{q,i})^2}$$

Luego, la distancia del coseno está definida de la siguiente manera

$$Fd_{cos} = \frac{1}{k(k-1)} \sum_{p,q \in U} x_{u,p} \cdot x_{u,q} \cdot d_{cos}(p, q),$$

$$d_{cos}(p, q) = 1 - \frac{v_p \cdot v_q}{\|v_p\| \|v_q\|}$$

Donde v_p es un vector de características de las películas es decir, géneros, ranking, etcétera de la película p de forma análoga para q .

Luego, realizamos sumas ponderadas para para transformar todos nuestros objetivos

$$\max_{u \in U} Y \{Fe(u), Fn(u), Fd(u)\}$$

Restricciones

1. Disponibilidad: sólo se pueden realizar recomendaciones de películas p que estén en el conjunto de las películas disponibles U .

$$x_{u,p} = 0, \quad \forall p \notin U.$$

2. Tamaño fijo de películas a recomendar: la recomendación para el usuario u debe contener exactamente k películas.

$$\sum_{p \in U} x_{u,p} = k, \quad \forall u.$$

3. Rating mínimo para la recomendación: no se recomendarán películas que el usuario u haya valorado por debajo de η_{min} .

$$x_{u,p} = 0 \quad \text{si} \quad r_{u,p} < \eta_{min}.$$

4. Restricción de usuario: no repetir que un usuario u ya haya valorado anteriormente.

$$x_{u,p} = 0, \quad \forall p \in I(u).$$

5. Se define una variable auxiliar $z_{u,g} \in \{0, 1\}$ que indican si en la lista de usuarios u aparece al menos una película del género g .

$$\sum_{p \in U} x_{u,p} \cdot g_{p,g} \geq z_{u,g}, \quad \forall g, u$$

6. Géneros distintos: se suma de todos los géneros debe ser menor a m .

$$\sum_g z_{u,g} \geq m \quad \forall u.$$

7. Popularidad total: la suma de toda la popularidad de las películas no puede superar cierto limite T_{Pop} .

$$\sum_{p \in U} \text{Pop}(p) \cdot x_{u,p} \leq T_{Pop} \quad \forall u.$$

8. Novedad individual: no se puede recomendar una película cuya novedad sea menor a T_{Nov} .

$$x_{u,p} = 0 \quad \forall p \quad \text{con} \quad 1 - P(\text{Visto} \mid p) \leq T_{Nov}.$$

9. No duplicidad de las recomendaciones de un usuario: la variable de decisión debe dar valores estrictamente binarios (1 para recomendar, 0 para no recomendar).

$$x_{u,p} \in \{0, 1\} \quad \forall u, p$$

Algoritmo NSGA-II

NSGA-II, Non Sorting Genetic Algorithm ayuda a resolver problemas multiobjetivo que llegan a ser conflictivos buscando un conjunto de soluciones no dominadas (frente de pareto) en un espacio de soluciones. [3]-[5]

NSGA-II se enfoca en resolver problemas con M funciones objetivo que queremos minimizar o maximizar simultáneamente

$$\min_{x \in \Omega} f(x) = (f_1(x), f_2(x), \dots, f_M(x))$$

Donde Ω es el espacio factible de soluciones que posee el problema a resolver donde se busca una dominancia de pareto [6] donde se busca una solución a que domina a otra solución b tal que

$$\forall i \in \{1, 2, \dots, M\}, \quad f_i(a) \leq f_i(b) \rightarrow \exists j : f_j(a) < f_j(b),$$

además, se buscan soluciones de un conjunto de Pareto de soluciones no dominadas.

El NSGA-II está compuesto de los siguientes pasos. [7]

1. **Inicialización:** Se genera una población inicial M_0 con tamaño N , cada individuo x representa una solución candidata a ser buena.
2. **Verificar soluciones dominadas:** para cada solución se debe verificar si hay soluciones dominadas, para ello, se ordena la población M_t según la dominancia tal que
 - F_1 =conjunto de soluciones no dominadas
 - F_2 =conjunto de soluciones dominadas solo por las de F_1 .
 - F_3 =conjunto de soluciones dominadas solo por las soluciones F_1 y F_2 , y así sucesivamente.

Luego, tiene que para cada solución P, Q , se define un $S_P : \{Q \mid P \text{ domina } Q\}$ con n_P el número de soluciones que dominan a P , similarmente se puede realizar para Q . Luego, se cumplen las siguientes condiciones del proceso

- Todas las soluciones con $n_P = 0$ si $n_P \in F_1$.
- Para toda solución $P \in F_1$, se deduce que en n_Q para cada $Q \in S_P$ en 1.
- Las soluciones que quedan con $n_Q = 0$ pasan a F_2

Luego, se repiten los pasos anteriores para verificar si hay soluciones dominadas. El proceso anteriormente descrito se puede visualizar de la siguiente forma. [4]




Figura 1: Verificación de funciones ponderadas

3. **Distancia de Multitud:** Para mantener diversidad en la población, se calcula la distancia de la masa de población para cada solución que pertenece a un frente de Pareto, esta es la manera de medir la distancia entre las soluciones. Además, las soluciones con mayor distancia entre ellas son las preferidas para que sean uniformes. Matemáticamente se puede ver como cada objetivo se ordena en el frente F según el objetivo f_i se tiene que la distancia

$$\mathcal{D}(x_j) = \sum_{i=1}^L \frac{f_i(x_{j+1}) - f_i(x_{j-1})}{f_i^{\max} - f_i^{\min}}$$

Donde $f_i(x_j)$ es el valor de i -ésima función objetivo de la solución x_j y L la cantidad de funciones objetivo. Además, $f_i^{\max}, f_i^{\min}$ son los valores máximos y mínimos respectivamente del i -ésimo objetivo del frente de Pareto evaluado. Gráficamente se puede visualizar de la siguiente forma.[4]




Figura 2: Distancias de las multitudes

4. **Selección y generación de descendencia:** Se realiza un torneo binario con la siguiente regla para escoger a los padres de la descendencia. Durante el torneo, se comparan dos soluciones: la que pertenece al frente de Pareto más bajo se selecciona; si ambas pertenecen al mismo frente, se elige a la que tiene mayor distancia de multitud. Con los padres seleccionados, se genera un cruzamiento y una mutación entre ellos para generar la descendencia O_t .
5. **Formación de una nueva generación:** se combina la población actual M_t y la descendencia actual O_t para generar la nueva generación tal que

$$\mathcal{R}_t = M_t \cup O_t$$

Se ordena $\mathcal{R}_t$ por frentes y se llena la siguiente población M_{t+1} con los frentes más dominantes en orden hasta completar N individuos.

Si cuando se añade un nuevo frente F_i excede N , se ordena F_i por la distancia de multitud y se seleccionan los primeros para completar la nueva generación.

Estas nuevas generaciones, que son las nuevas-mejores soluciones se evalúan en la suma ponderada de funciones objetivo.

6. **Combinación de poblaciones:** se combinan las soluciones generadas para formar una población con un tamaño $2N$.
7. **Clasificación y selección:** la población combinada se clasifica nuevamente por frentes no dominados y se calcula la distancia de la multitud para cada solución. Se seleccionan las mejores soluciones para generar la próxima generación priorizando las soluciones con mayor distancia, luego se repite el proceso del algoritmo.
8. **Criterio de terminación:** El proceso se repite el proceso de selección, cruce, mutación y actualización de generaciones hasta que se cumpla un criterio de terminación. Los criterios de terminación varían de la implementación. Particularmente un buen criterio de parada nos pareció fijar un número de generaciones en particular dado que, al momento de llegar a esa generación se detiene el algoritmo.

Implementación en Código

Para poder tratar con los datos de las películas tomamos los archivos y creamos una matriz de películas en las filas y géneros en las columnas así como un diccionario de películas con sus respectivos géneros. Luego, definimos la función que nos evaluará la precisión del listado; en ella se crea y normaliza una matriz de popularidad generada en función a qué cantidad de personas le han dado un rating a cierta película, sea este alto o bajo. Posteriormente, definimos la función que nos evaluará la precisión de la lista de recomendaciones; en ella creamos un perfil del usuario en función a las películas que este ha visto, el cual usaremos para definir unas preferencias las cuales usaremos para la métrica de precisión. Por último, definimos una función que mida la diversidad entre elementos de la lista; para ello nos servimos de la distancia del coseno para sacar la distancia entre los elementos de la lista.

Teniendo nuestras funciones de métricas, obtenemos la lista de candidatos con todas las películas que no hayan sido vistas por el usuario y que tengan una novedad mayor a 1 menos el máximo percentil de popularidad deseado. Posteriormente, creamos el objeto de "FitnessM", el cual, por medio de métodos propios de él, servirá como base para la aptitud de las opciones considerando la maximización de cada una de las métricas. A su vez, es creada la clase "Individual" los cuales serán el nuevo tipo de datos a evaluar en el problema de optimización. Estos últimos son considerados los cromosomas del problema de optimización, los cuales irán mutando de iteración en iteración para llegar a un individuo óptimo [6]. Con estas condiciones podemos aplicar el algoritmo evolutivo NSGA-II el cual evaluará,

mutará, cruzará y seleccionará a los individuos a lo largo de varias generaciones para encontrar el frente de Pareto. Para la implementación del sistema de recomendación a nuevos usuarios se añadió una función que permite registrar nuevos usuarios al registro.

RESULTADOS

Para los resultados planteamos 2 tipos de casos, esto con el propósito de entender los alcances del código con mayor o menor numero de evaluaciones:

Caso 1: Escogemos al usuario con el número de ID 1 de la base de datos de ranking, el cual realizó un total de 232 reseñas (Tabla 1).

Título	Calificación
Seven (a.k.a. Se7en) (1995)	5.0
Usual Suspects, The (1995)	5.0
Bottle Rocket (1996)	5.0
Dumb & Dumber (Dumb and Dumber) (1994)	5.0
Billy Madison (1995)	5.0
:	:
Toys (1992)	2.0
Psycho (1998)	2.0
I Still Know What You Did Last Summer (1998)	2.0
Mummy, The (1999)	2.0
Talented Mr. Ripley, The (1999)	1.0

Tabla I: Reseñas del usuario con ID 1 (total = 232)

Aplicando el programa, el resultado fue una tabla con las siguientes características, una precisión del 0.6194, una novedad del 0.908 y una diversidad del 0.659. Esto quiere decir que la lista creada es una con películas poco vistas entre el público en general, diversa entre los géneros que propone y cercana a los gustos que posee el usuario. La tabla entregada es:

movielfid	Título	Géneros
73321	Book of Eli, The (2010)	[Action, Adventure, Drama]
152079	London Has Fallen (2016)	[Action, Crime, Thriller]
2735	Golden Child, The (1986)	[Action, Adventure, Comedy, Fantasy, Mystery]
5944	Star Trek: Nemesis (2002)	[Action, Drama, Sci-Fi, Thriller]
7143	Last Samurai, The (2003)	[Action, Adventure, Drama, War]
27790	Millions (2004)	[Children, Comedy, Crime, Drama, Fantasy]
61248	Death Race (2008)	[Action, Adventure, Sci-Fi, Thriller]
317	Santa Clause, The (1994)	[Comedy, Drama, Fantasy]
2599	Election (1999)	[Comedy]
1907	Mulan (1998)	[Adventure, Animation, Children, Comedy, Drama...]

Tabla II: Películas asociadas al usuario con ID 1

Frente de Pareto – 3 objetivos




Figura 3: Frente de Pareto del ID1

Frente de Pareto (3 objetivos)




Figura 4: Frente de Pareto del usuario del ejemplo

Caso 2: Generamos un usuario con menos número de calificaciones, en este caso con 3 (Tabla 3), esto con el fin de identificar la cercanía con las películas propuestas.

ID	Título	Calificación
0	Toy Story (1995)	5.0
1	Pulp Fiction (1994)	4.5
2	Twelve Monkeys (a.k.a. 12 Monkeys) (1995)	4.0

Tabla III: Películas y calificaciones de ejemplo

Se aplicó el programa y el resultado fue una tabla con una precisión del 0.445, una novedad 0.9771 y una diversidad de 0.8787. Esto nos quiere decir que va a ser una tabla con películas poco vistas, distintas entre sí y cercanas a los gustos que tiene el usuario. La tabla que entregó fue la siguiente:

movieId	Título	Géneros
168418	The Boss Baby (2017)	[Animation, Children, Comedy]
68945	Neon Genesis Evangelion: Death & Rebirth	[Action, Animation, Mystery, Sci-Fi]
45668	Lake House, The (2006)	[Drama, Fantasy, Romance]
2470	Crocodile Dundee (1986)	[Adventure, Comedy]
156675	Project X (1968)	[Mystery, Sci-Fi]
2179	Topaz (1969)	[Thriller]
102720	Epic (2013)	[Adventure, Animation, Fantasy]
4093	Cop (1988)	[Thriller]
4043	At Close Range (1986)	[Crime, Drama]
177615	Lady Bird (2017)	[Comedy]

Tabla IV: Películas asociadas al usuario del ejemplo

Podemos observar que recomendó películas con características comunes a las que el marco con 5, animación en películas como “The Boss Baby” y “Neon Genesis Evangelion” al igual que la película “Toy Story”. Sci-Fi en películas como “Project X” y Thriller con “Topaz” y “Cop”. Además es un la lista es variada teniendo 12 diferentes géneros a lo largo de las recomendaciones.

Podemos afirmar que, entre estos dos casos, el que generó un mayor número de recomendaciones dio más peso a la precisión en la lista, mientras que el que produjo menos recomendaciones priorizó la diversidad y la popularidad.

ANÁLISIS DE SENSIBILIDAD

Ahora realizaremos un análisis de sensibilidad de acuerdo con 3 variables aumentado los parámetros “MIN GENRES”, “Gen” y “POP SIZE” y ver como varia el valor acumulado de los indicadores de “Precisión”, “Novedad” y “Diversidad”.

Efecto de “MIN GENRES”

MIN_GENRES	Precisión	Novedad	Diversidad	Z
3	0.6194	0.9085	0.6594	2.1873
6	0.6194	0.9085	0.6594	2.1873
7	0.6194	0.9085	0.6594	2.1873
8	0.2874	0.9942	0.9542	2.2358
11	0.5272	0.9439	0.7816	2.2527
12	0.3140	0.9991	0.9717	2.2848
16	0.3297	0.9966	0.9490	2.2753
17	0.3902	0.9686	0.9137	2.2725

Tabla V: Resultados para diferentes valores de MIN_GENRES

Se puede observar que para valores bajos de 3 a 7, la restricción no induce ningún cambio: el algoritmo encuentra la misma solución y todas las métricas se mantienen. A partir de ocho géneros, la lista se ve obligada a incorporar títulos adicionales para cubrir mayor variedad; por tanto, la precisión cae bruscamente, ya que se introducen películas menos afines al perfil. La novedad y la diversidad aumentan casi al máximo,

pues es necesario buscar películas poco comunes y de géneros distintos. El indicador compuesto Z mejora ligeramente porque recompensa la ganancia en novedad y diversidad más de lo que penaliza la caída de precisión.

Efecto de “N GEN”

Gen	Precisión	Novedad	Diversidad	Z
60	0.6194	0.9085	0.6594	2.1873
120	0.6317	1.0000	0.5698	2.2015
240	0.6341	1.0000	0.5610	2.1951
480	0.6467	1.0000	0.5384	2.1851

Tabla VI: Resultados para diferentes cantidades de generaciones

Se observa que, al duplicar el número de generaciones de 60 a 120, el algoritmo obtiene listas ligeramente más precisas, pero sacrifica diversidad. Entre 120 y 480 generaciones, la precisión continúa aumentando muy lentamente, la novedad permanece fija en 1 y la diversidad desciende. En consecuencia, puede concluirse que entre 100 y 150 generaciones se alcanza un buen equilibrio; más iteraciones tienden a sobre optimizar precisión y novedad a costa de la diversidad y añaden coste computacional.

Efecto de “POP SIZE”

POP_SIZE	Precisión	Novedad	Diversidad	Z
120	0.6194	0.9085	0.6594	2.1873
240	0.3016	0.9954	0.9779	2.2749
480	0.2747	0.9991	0.9761	2.2499
960	0.5114	0.9851	0.8095	2.3060

Tabla VII: Resultados para diferentes valores de POP_SIZE

Podemos observar que, al aumentar el tamaño de la población, la búsqueda se dispersa y NSGA-II tiende a seleccionar soluciones más extremas, aunque menos precisas. Con POP de 240 y 480 se alcanza la diversidad máxima y una novedad cercana a 1, pero se sacrifica gran parte de la precisión. Con POP 960 la diversidad se reduce ligeramente a 0.81, mientras que la precisión se sube hasta 0.51, lo que arroja el mejor Z global de 2.306. Esto sugiere que una población grande permite hallar un punto de Pareto más equilibrado, aunque con un alto gasto computacional.

CONCLUSIONES

- El proyecto logró integrar con éxito un modelo de recomendación multi-objetivo, considerando precisión, novedad y diversidad para realizar una recomendación al usuario. este enfoque tuvo una ventaja particular y es que, al tener varios objetivos nos permitió diversificar la forma en la que se puede realizar el tipo de recomendación aplicando, de forma matemática, algoritmos de solución multi-objetivo ofreciéndonos resultados bastante sorprende en cuanto a lo esperado por los objetivos propuestos para generar las recomendaciones del usuario.

- Se demostró que al imponer mayores restricciones para la diversidad hacia que el modelo fuera más sensible hacen que, el modelo ofrezca más diversidad y novedad a cambio de la precisión. Además, un aumento en el número de generaciones o de la población inicial en el algoritmo NSGA-II aplicado para la solución de nuestro problema, evidenciaba un aumento del conjunto de soluciones factibles ofreciendo mayor calidad en las respuestas realizadas por los frentes de Pareto.
- Se evidenció una ventaja notable al no sólo enfocarnos en la precisión para recomendar películas ya que permitió al modelo ofrecer una amplia gama de géneros al usuario añadiendo la novedad y diversidad a la recomendación; ofreciendo un mayor contenido para el disfrute y dando así opciones al usuario de elegir un contenido multimedia interesante.

REFERENCIAS

- [1] M. Bavera, B. Barán y U. Yael, “Sistema híbrido de recomendación. Un sistema multi-objetivo no convencional,” en *XLV Conferencia Latinoamericana de Informática (CLEI 2019)*, Asunción, Paraguay: CLEI, 2019. dirección: <https://clei.org/clei2019>.
- [2] F. M. Harper y J. A. Konstan, “The MovieLens Datasets: History and Context,” *ACM Transactions on Interactive Intelligent Systems (TiiS)*, vol. 5, n.º 4, págs. 1-19, 2015. DOI: 10.1145/2827872. dirección: <http://dx.doi.org/10.1145/2827872>.
- [3] ESA Pagmo2 Team, *NSGA-II: Non-dominated Sorting Genetic Algorithm II*, <https://esa.github.io/pagmo2/docs/cpp/algorithms/nsga2.html>, Último acceso: 2025-05-20, 2025. dirección: <https://esa.github.io/pagmo2/docs/cpp/algorithms/nsga2.html>.
- [4] pymoo developers, *NSGA-II Algorithm*, <https://pymoo.org/algorithms/moo/nsga2.html>, Último acceso: 2025-05-20, 2025. dirección: <https://pymoo.org/algorithms/moo/nsga2.html>.
- [5] K. Deb y H. Jain, “An Evolutionary Many-Objective Optimization Algorithm Using Reference-Point-Based Nondominated Sorting Approach, Part I: Solving Problems With Box Constraints,” *IEEE Transactions on Evolutionary Computation*, vol. 18, n.º 4, págs. 577-601, 2014. DOI: 10.1109/TEVC.2013.2281535.
- [6] F.-A. Fortin, F.-M. De Rainville, M.-A. Gardner, M. Parizeau y C. Gagné, “DEAP: Evolutionary Algorithms Made Easy,” *Journal of Machine Learning Research*, vol. 13, págs. 2171-2175, jul. de 2012.
- [7] GeeksforGeeks Contributors, *Non Dominated Sorting Genetic Algorithm 2 (NSGA-II)*, <https://www.geeksforgeeks.org/non-dominated-sorting-genetic-algorithm-2-nsga-ii/>, Último acceso: 2025-05-20, 2025. dirección: <https://www.geeksforgeeks.org/non-dominated-sorting-genetic-algorithm-2-nsga-ii/>.
- [8] U. M. Diwekar, *Introduction to applied optimization*. Springer Nature, 2020, vol. 22.